

社会で活用されるデータ

具体的にどのようなデータが活用されているか
例をいくつか見てみよう

1

動線データ

人や自動車の位置・移動に関する行動データ

- スマホの位置・移動データ (GPS, 電話基地局, WiFiエリア)
- カーナビの位置・移動データ
- 監視カメラ映像・衛星画像の分析データ
 - 動画 → 動体の分析
 - 画像 → 人・自動車の同定 (顔認識, ナンバープレート読取)
- 交通系ICカードの利用データ

など

3

行動データ

人の行動に関するデータ

- いつ, どこで, 誰が, 何をしたか
 - 物理的な位置・移動 → 動線データ
 - 物理的な活動 (どこで, 何ををしたか)
 - ネットワーク上での活動 (どこで, どのような操作をしたか)
 - ネットワーク上での関係 (誰と or 何と, どのような関係か)

※ 個人情報でもあり, 特に「誰が」や「誰と」の情報は, 匿名化しなければプライバシー保護の問題を生じるので要注意

2

動線データの活用

- 人や自動車がどこに集中しているか, どこが混雑しているか
- 人や自動車がどこからどこに移動しているか

↓ これらの情報を時刻・曜日・季節等に沿って収集

- 物流をスムーズに管理 (ロジスティクス)
- 店舗や地域内での人の動線をマーケティングに生かす
 - 人の流れをスムーズに誘導する
 - 目につくところに広告・売れ筋商品など
- 渋滞や混雑のリアルタイム情報や将来予想

4

ネットワーク上の行動データ

- 検索履歴 – どのようなキーワードで検索したか
- アクセス履歴 – どこから何をアクセスしたか (Webページ, 他)
- SNS上の人間関係 – リプライ, フォロー, フレンド
- データ間のひもづけ：
 - サインイン (ログイン) – 個人の同定
 - cookie – セッションの同定

5

ネットワーク上の行動データの利用

- 広告のカスタマイズ (パーソナライズ)
- SNS表示・ニュース表示等のカスタマイズ (パーソナライズ)
⇒ エコーチェンバー現象, サイバーカスケード の要因に
- マーケティングに関する情報の収集
例えば ...
 - どのようなデザインが好まれるか
 - どのようなデザインがアクセスを誘導するか
- ネットワーク上の行動の誘導などに応用

6

機器のログデータ

- これもまた, ある種の行動データ：
 - どこ (どの機器) から
 - どこ (どの機器) を経由して
 - どこ (どの機器) にアクセスしたか
- というデータ ⇒ ネットワーク上の行動データ
- 一連の接続を同定するには, 時刻を手掛かりにする
 - 全ての機器の「時計」が正確でなければ正しく解析できない
 - NTP (Network Time Protocol) を用いて時刻を同期

7

オープンデータ

- 一般に向けて公開されているデータ
- 公共性のあるデータが多いが, それ以外もある
 - 公的機関 (省庁, 地方公共団体, 研究機関など) 他
- 最近はWWW上での公開も増えている
 - ファイル (テキスト, PDF, CSV, (Word, Excel, Powerpoint) 等)
→ ダウンロードして利用
 - ダッシュボード
→ インタラクティブなWebページで
種々のデータを図表やグラフで見やすく表示

8

1次データ／2次データ／メタデータ

- 1次データ (1次資料)
 - 事象や出来事の情報をも直接記録したもの
 - 電子化されているとは限らない
 - 誇張, 偏向, 錯誤等があることも (ex. 戦闘詳報)
- 2次データ (2次資料)
 - 1次データを元にまとめなおしたもの
 - 情報を取捨選択したり, 見やすく変換したり
 - 情報の欠落, 内容の誤解, 転記ミス等があることも

9

1次データ／2次データ／メタデータ (つづき)

- ※ 客観的 (と思われる) データなら, なるべく1次データにあたる
- ※ 解釈の難しいデータなら, 信頼できる2次データにあたる方が
良いことも (専門家の知見を信頼する)
- メタデータ
 - (1次データ, 2次データ等の) データそのものに関するデータ
 - 例えば, 内容の説明, タイトル, 情報源, 取得日時, 記述形式 等々
 - 元データを分析, 処理する際の重要な手掛かりとなる

10

構造化データ／非構造化データ

- 構造化データ – 形式がきちんと定義されている 定型的なデータ
 - 表の形 (RDB = データレコードの集合 の形) のものが多い
 - オープンデータでは, **CSV**(後述) で提供されるものも多い
 - それ以外のもの (もう少し複雑なもの) もある
 - XML – 構造を持った文書やデータをテキストで記述
 - JSON – オブジェクト (コンピュータで扱う構造化データ) を テキストで記述

※ これらは形式の定義が緩やかな場合, やや非構造的なことも

11

CSV (Comma Separated Values)

行と列を持つ表を テキストで記述したもの

- 表の行 → テキストの1行
- 表の列 (セル) → コンマ (,) で区切る
 - セルの内容が文字列の場合は, 引用符 (") でくくられることもある

※ テキストで表現されているので 可読性があり, 互換性が高い
→ オープンデータによく用いられる

12

CSV の例

表

No.	商品名	売上高 (円)
1	鉛筆	4230
2	シャープペンシル	12360
3	三色ボールペン	32810

CSV

```
"No.", "商品名", "売上高 (円)"  
1, "鉛筆", 4230  
2, "シャープペンシル", 12360  
3, "三色ボールペン", 32810
```

13

動線データ利用の例

- モバイル空間統計 人口マップ (<https://mobakumap.jp/>)
- 混雑予報 - NAVITIME
(<https://www.navitime.co.jp/congestion/prediction/>)
- スポット周辺の渋滞予測 - NAVITIME
(<https://www.navitime.co.jp/probetraffic/>)

15

構造化データ／非構造化データ (つづき)

- 非構造化データ – 構造のない非定型的なデータ
 - フラットなテキスト, 画像, 音声など

非構造的な1次データは, これまでは取り扱いが難しかったが, 近年, 取り扱う技術が発達して, 蓄積・利用が増大傾向にある

- 構造化された2次データに変換して利用することも
 - フラットなテキスト → 形態素 (単語) のリスト
→ 出現頻度／共起表現
 - 画像 → (写っている物の) タグ付き画像 (= 部分的な構造化)

14

オープンデータの例

- [気象庁 | 過去の気象データ・ダウンロード](#)
- [e-stat](#) 政府統計の総合窓口
 - [統計ダッシュボード](#)を見てみよう
 - さまざまなグラフを見てみよう
 - [地域のレーダーチャート・ランキング](#)も見てみよう
 - [統計地理情報システム](#) から jSTAT MAP も使ってみよう

16