

さまざまなデータ処理の技術

データ解析やAIでは、どのような技法が使われているのだろうか


1

データ解析とは

- データ集計, 抽出
- データの性質・関係性の把握
 - 基本統計量, ヒストグラム, クロス集計 等
- 検定
 - 性質・関係性の有意性を判定
- 予測・推測・判別 (分類)
 - 回帰モデル, 決定木モデル, ニューラルネットワーク 等
- グルーピング
 - クラスター分析
- パターン発見
 - データマイニング
- 最適化
 - 制約条件下で目的関数を最小化 (または最大化)
- シミュレーション
 - モデル構築, 条件設定

2


データ解析の例 – 予測・推測



- データ: 1897~2025
回帰直線: 朱の実線
※ 点線は $\pm 2.5^{\circ}\text{C}$
↓
- 補外 (予測・推測)
 - 前方: 2026~2050
 - 後方: 1890~1896

3

データ解析の例 – グルーピング



- クラスター分析
(クラスタリング)
クラスター(まとまり)を見つける
- 左図のデータは2群に分けられそう
↓
- クラスターの境界を定めると, 新しいデータも分類できる (判別)

4

データ解析の例 – パターン発見

パターン発見 = 規則性を見出すこと

- 仮説検証によるパターン発見
例: 年間のデータ変動から季節変動を推定して検証 (cf. p.66, fig.5-3)
- 探索的データ解析によるパターン発見
例: ビッグデータから, AI によってパターンを学習 (パターン認識)

※ 前者は従来から行われてきたが, 先入観に捉われることも

※ 後者はAIの発達によって, 意外な発見もできるように
(データマイニング)

5


データ可視化の方法 – グラフ

- ヒストグラム, 箱ひげ図 – (1変数)データの分布
- 散布図 (cf. スライド 3, 4) – 2変数データの分布
- 棒グラフ, 折れ線グラフ – $x \rightarrow f(x)$
- 円グラフ, 帯グラフ – $x \rightarrow f(x), \sum f(x) = 1$
- 集合棒グラフ, 3D棒グラフ – $(x, y) \rightarrow f(x, y)$
- 散布図行列 – 複数の変数の全てのペアの散布図の行列
- 複合グラフ – 複数種類のグラフの合成
 - 2軸グラフ – 縦軸が2種類あるグラフ (cf. p.68, fig.5-4)

6


グラフの例 – ヒストグラム, 箱ひげ図

ヒストグラムの例



アイリスの花弁の長さの分布 (cm)

箱ひげ図の例




アイリスの花の測定データの分布

7


グラフの例 – 集合縦棒, 3D縦棒

集合縦棒の例




■ A ■ B

3D縦棒の例



8

グラフの例 — 散布図行列





- 複数の変数から2変数を選び、各ペアごとの散布図を行列にしたもの
- 対角線にあたる場所は、対応する変数のヒストグラムになっている。

(クリックで別途表示します)

データ可視化の方法 — 図示

- 関係性の可視化 — 階層構造・ネットワーク構造の図示 など



- 地図上の可視化 (cf. p.69, ffig.5-5, 5-6)

9

10

非構造化データの処理

- 言語処理の例
 - 形態素解析： 文を形態素(単語)に切り分ける
 - 構文解析： 文法に従って文の構造を解析する
 - 単語出現頻度： 文章中の単語の出現頻度を数える (→ ワードクラウド)
 - 共起関係の分析： 同じ文の中に現れる語同士の関係を調べる
 - 文章生成： 翻訳・要約・質問への応答など

(cf. [AIテキストマイニング](#))

非構造化データの処理

- 画像処理の例
 - 画像の認識： 何が写っているか、どこに何があるか (顔認識も)
 - 画像の修正： 写っているものの修正、消去、差し替えなど
 - 画像の生成： 「指示」に沿った画像の自動生成など
- ※ 静止画も動画も
- 音声処理の例
 - 言語音の認識： 何と言っているか
 - 音声合成

11

12

AIの技術（機械学習）

データ解析や非構造化データの処理には機械学習が成果を上げている

- 教師あり学習


- 問題と正解がセットになった訓練データで学習
(正解を教えてくれる教師がいるということ)

問題に対してシステムが出した解答を正解と照合,
解答を正解に近づけるようにシステムを学習させる

13

AIの技術（機械学習）

- 教師あり学習



14

AIの技術（機械学習）

- 教師なし学習

- 与えられたデータだけから, 特徴やパターンなどを見出す学習
(cf. p.77, fig.5-10, Face Node, Cat Node)
- クラスタリングも広い意味では教師なし学習

- 強化学習

- (一つの, あるいは一連の)選択に対して報酬を与える
- さまざまな選択を試行錯誤し, 報酬の高い選択を選ぶように学習する (= 報酬の高い選択の頻度が高まるように強化する)

15

AIの技術（機械学習）

- 深層学習 (ディープラーニング)

- ニューラルネットワークを4層以上にしたもの
(cf. テキスト pp.76-77, Sc387(1) 人工知能論)
- 教師あり学習と教師なし学習 (自己符号化器による事前学習) を組み合わせて学習させる
- 画像処理など, さまざまな分野で応用が研究されている

- 転移学習

- 学習済みのAIシステムの一部 (通常, 入力に近い部分) を他のシステムに流用すること

16

AIの技術（機械学習）

- 生成AI
 - 与えられた指示 (プロンプト) に応じて, 文章, 画像, 動画, 音楽, 音声などのコンテンツを自動的に生成するAI
 - 各コンテンツの膨大な事例を学習して, 自然な (いかにもありそうな) コンテンツを生成する

17

データ解析の例 (つづき)

- 検索条件で, 神戸市の過去の8月の平均気温データを指定する
 - 地点を選ぶ: 兵庫 → 神戸
 - 項目を選ぶ: データの種類 = 月別値, 項目 = 月平均気温
 - 期間を選ぶ: 特定の期間を複数年分、表示する
8月から 8月の値を 1897年 から 2025年 まで表示
 - 表示オプションを選ぶ:
ダウンロードCSVファイルのデータ仕様:
すべて数値で格納(...) → 年月日などに分けて格納

19

データ解析の例 – 回帰

気象庁のオープンデータを利用して, 将来予測をしてみよう

- 準備
 - ドキュメントフォルダーに Sc188 というフォルダーを作る
- 気象庁のサイトにアクセスする
 - 気象庁 | 過去の気象データ・ダウンロード

18

データ解析の例 (つづき)

- データをダウンロードして, Excel のファイルに変換する
 - CSVファイルをダウンロードする ボタンをクリックして, Sc188 にダウンロードする
 - わかりやすく名前を付けるとよい. KobeAug.csv とか
 - ダウンロードしたファイルを Excel で開き, 名前を付けて保存 で, ファイルの種類を Excel ブック (*.xlsx) として保存しなおす

20

データ解析の例 (つづき)

- 元データを保存しておくために、ワークシートを複製しておく
 - ワークシートのタブ (下端) を右クリックして 移動またはコピー... から コピーを作成する にチェックをつけて OK とする
- 複製したワークシート上で、使わない部分を削除する
 - 品質番号, 均質番号の列 (D,E列), 月の列 (B列) を削除
 - 月の情報が削除されたので、見出しの 平均気温(℃) は 8月の平均気温(℃) としておく
 - 空行になった5行目も削除

21

データ解析の例 (つづき)

- 横軸を年、縦軸を平均気温として散布図を描く
 - 見出しとデータの範囲 (A4:B133) を選択して 挿入-グラフ-散布図 を選び、散布図を作成する (cf. Excel 資料)
 - 散布図の種類は、直線とマーカー を選ぶと見やすいかも
 - グラフの大きさ、形など、見やすく変更してもよい
 - デザイン-グラフ要素の追加 で、補助目盛線 を追加してもよい
 - 縦軸・横軸の書式設定では、境界値の最大値, 最小値 や、目盛線の単位 を指定できる

22

データ解析の例 (つづき)

- 散布図に回帰直線 (線形近似直線) を引く
 - グラフを選択し、グラフツール - デザイン - グラフ要素を追加 - 近似曲線 - 線形 を選択する (cf. Excel 資料)
- 回帰直線の書式を操作する
 - 描画された回帰直線を 右クリック し、近似曲線の書式設定 を選ぶ
 - 直線の前後への延長は、前方補外, 後方補外 で設定できる (1880年から2040年まで広げてみよう)
 - グラフに数式を表示する で、回帰直線の式が表示できる

23