

データ分析の基本

今回から、データ分析の技術的な話になります。

データの種類 (§6-1)

- **質的データ** (定性的尺度)
 - 名義尺度
 - 順序尺度
- **量的データ** (定量的尺度)
 - 間隔尺度
 - 比例尺度
- (量的データの別の分類)
 - 連続データ
 - 離散データ

1

2

質的データ

- **名義尺度**
 - 順序関係のない、他と区別するため (だけ) の値を取るデータ例えば, 血液型, 出席番号 など
- **順序尺度**
 - 順序は定まっているが, その「程度」が数量的な値としては定まっていないようなデータ例えば, サイズ (S, M, L), 順位 (1位, 2位, ...) など

3

量的データ

- **間隔尺度**
 - 数値データで, その間隔が量としての意味を持つようなデータ
 - 数値の起点 (ゼロ点) は便宜的に決められ, 特別な意味を持たない例えば, 摂氏温度, 日付 など
- **比例尺度**
 - 数値データで, その比が量としての意味を持つようなデータ
 - 数値の起点 (ゼロ点) は一意に定まっている例えば, 身長, 体重, 絶対温度, 日数(期間), 預金額 など

4

連続データ と 離散データ

• 連続データ

- 連続的な数値 (実数値) で表されるようなデータ

例えば, 身長, 体重, 温度 (摂氏温度, 絶対温度) など

• 離散データ

- 自然数や整数などの, とびとびの値で表されるようなデータ

例えば, 日付, 日数(期間), 預金額 など

※ いずれも, 間隔尺度, 比例尺度の両方がありうる

5

1変数データの基本統計量 (§6-2)

• 代表値

- 平均値
- 中央値 (メジアン)
- 最頻値 (モード)

• 散らばりの指標

- 最大値, 最小値, 範囲 (レンジ)
 - (外れ値)
- 分散・標準偏差
 - 不偏分散・不偏標準偏差
- (四分位数,) 四分位偏差

※ 上記の散らばりの指標は, すべて量的データに用いられる

6

〔以下, n 個のデータ $x_1, x_2, \dots, x_n$ を対象として仮定する〕

代表値 – 平均値

- **平均値** : データの総和をデータの個数で割ったもの (算術平均)

$$\frac{1}{n}(x_1 + x_2 + \dots + x_n) = \frac{1}{n} \sum_{i=1}^n x_i$$

- 量的データに用いる (質的データには使えない).
- ほぼ真ん中の値になる
- 外れ値 (とびぬけて大きい, または小さい値) の影響を受けやすい (外れ値のある方へ引っ張られる)

7

代表値 – 中央値 (メジアン)

- **中央値 (メジアン)** : 値の順に一系列に並べた時, 中央の位置に来る値

$$\begin{cases} n \text{ が奇数の時: } x_{\frac{n+1}{2}} \\ n \text{ が偶数の時: } \frac{1}{2} (x_{\frac{n}{2}} + x_{\frac{n}{2}+1}) \quad (\text{量的データの場合}) \end{cases}$$

- 順序尺度や量的データに用いる (名義尺度には使えない).
- ほぼ真ん中の値になる
- 外れ値の影響を受けにくい (頑健 である)

8


代表値 – 最頻値 (モード)

- **最頻値 (モード)** : もっとも度数の多い値
(度数 = 該当するデータの数)
 - 質的データや離散データに用いる (連続データには適さない).
 - 順序のある尺度で釣り鐘型の分布の場合, ほぼ真ん中の値になる
(釣り鐘型の分布 = 山が一つで左右対称の分布)
 - 外れ値の影響を受けにくい (頑健 である)

9

代表値の例

- 例えば, 1,2,3,3,3, 4,4,5,6,14 の10個のデータ (合計45) の場合
 - 平均値は 4.5 ($45 \div 10$)
 - 中央値は 3.5 ($((3+4) \div 2)$)
 - 最頻値は 3 (3個で最多)



10

散らばりの指標 – 範囲

- **最大値** : 一連のデータの中で最大の値
- **最小値** : 一連のデータの中で最小の値
- **範囲** (レンジ) : 最大値と最小値の差 (最大値 – 最小値)

※ 一般に範囲が大きいほど, データの散らばりは大きいと考えられるが, 外れ値の影響を受けやすい (cf. 前スライド)

※ 外れ値が「異常」な値とみなせる場合は, 除外して分析することもある

11

散らばりの指標 – 分散

- **偏差** : 各データ (x_i) の, 平均 ($\bar{x}$) との差 ($x_i - \bar{x}$)
- **偏差平方和** : 各データの偏差の2乗 (**偏差平方**) の総和
- **分散** : 偏差平方和をデータの個数で割ったもの (偏差平方の平均値)

$$\begin{aligned} & \frac{1}{n} \left((x_1 - \bar{x})^2 + (x_2 - \bar{x})^2 + \dots + (x_n - \bar{x})^2 \right) \\ &= \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \quad \left(= \left(\frac{1}{n} \sum_{i=1}^n x_i^2 \right) - \bar{x}^2 \right) \end{aligned}$$

※ 分散が大きいほど, データの散らばりは大きい

12

散らばりの指標 – 標準偏差

- 標準偏差：分散の平方根

$$\sqrt{\frac{1}{n} ((x_1 - \bar{x})^2 + (x_2 - \bar{x})^2 + \dots + (x_n - \bar{x})^2)}$$
$$= \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2} \quad \left(= \sqrt{\left(\frac{1}{n} \sum_{i=1}^n x_i^2 \right) - \bar{x}^2} \right)$$

※ 標準偏差が大きいほど、データの散らばりは大きい

13

散らばりの指標 – 四分位偏差

- 一連のデータを順序に従って並べ、小さいほうから4分の1, 2, 3 (25%, 50%, 75%) の位置にあたる数を第1, 第2, 第3四分位数という
- 第2四分位数は中央値 (メジアン) に等しい
- 第3四分位数と第1四分位数の差を四分位範囲といい、その2分の1を四分位偏差という

※ 四分位偏差が大きいほど、データの散らばりは大きい

※ 外れ値の影響を受けにくい (頑健である)

※ 四分位数の定義は何通りもある (が、データ数が多ければ大差がないので、あまり気にしなくてよい)

15

散らばりの指標 – 不偏分散・不偏標準偏差

- 標本 (サンプル) のデータから、母集団の分散・標準偏差を推定する場合、推定値として不偏分散・不偏標準偏差を用いる
- 通常分散 (標本分散) に対して、不偏分散はデータの個数 (n) で割るかわりに、データの個数 - 1 ($n - 1$) で割る。
- 不偏標準偏差は、不偏分散の平方根である

$$\text{不偏分散: } \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2, \quad \text{不偏標準偏差: } \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}$$

14

散らばりの指標の例 – 範囲・標準偏差

1, 2, 3, 3, 3, 4, 4, 5, 6, 14 の 10 個のデータの場合

- 最小値 / 最大値 / 範囲：1 / 14 / 13 (=14-1)
- 標準偏差：3.44 ($\doteq \sqrt{(474/4)/10}$)

そこから 14 を除いた 1, 2, 3, 3, 3, 4, 4, 5, 6 の 9 個のデータの場合

- 最小値 / 最大値 / 範囲：1 / 6 / 5 (=6-1)
- 標準偏差：1.42 ($\doteq \sqrt{(164/9)/9}$)

※ 外れ値 (14) の影響を大きく受けている

16

散らばりの指標 – 例（四分位偏差）

1, 2, 3, 3, 3, 4, 4, 5, 6, 14 の 10 個のデータの場合

- 第1四分位数 / 中央値 / 第3四分位数 : 3 / 3.5 / 5
- 四分位範囲 / 四分位偏差 : 2 (=5-3) / **1** (=2/2)

そこから 14 を除いた 1, 2, 3, 3, 3, 4, 4, 5, 6 の 9 個のデータの場合

- 第1四分位数 / 中央値 / 第3四分位数 : 2.5 / 3 / 4.5
- 四分位範囲 / 四分位偏差 : 2 (=4.5-2.5) / **1** (=2/2)


※ 外れ値 (14) の影響を余り受けない (頑健である)

17

1変数データの視覚的表現 – 箱ひげ図

- いくつかの基本統計量を集約して表示する

※ 平均値は描かないことも多い
※ 外れ値を分けない描きの方が標準的かも



18

1変数データの視覚的表現 – 度数分布 (表)

- 質的データ, 離散的データの場合, 各値ごとの度数を数えて並べる
 - 名義尺度の場合, 度数の多い順に並べかえることが多い
 - 順序尺度の場合, その順序に従って並べる
- 連続的データの場合, 有限個の区間に区切って度数を数え, 昇順 (または降順) に並べる
 - 区間は等間隔にすることが多い


※ 基本統計量では捉えきれない分布の特徴をとらえられる
※ 横幅で区間の長さ, 面積で度数を表す長方形を (くっつけて) 横に並べたグラフを **ヒストグラム** という

19

ヒストグラムの例


値	1	2	3	4	5	6	7	8	9	10	11	12	13	14
度数	1	1	3	2	1	1	0	0	0	0	0	0	0	1

↓ 質的データ, 離散的データの場合は等間隔とする



20

〔区間の幅が不均等なヒストグラムの例 (総務省統計局から引用)〕





多変数の分析 (§6-4)


- クロス集計
 - 複数の (変数の) 値の組で表されるデータを, その組み合わせに沿って集計し度数分布表 (**クロス集計表**) を作成すること
 - 集合縦棒や3D縦棒のグラフでも表現できる
 - [Excel のピボットテーブル機能](#)を使うと, クロス集計表が作れる
- 散布図
 - 連続データの場合は, 複数の値の組を多次元空間内の座標値とみなして**散布図** ([参考](#))を作成すると傾向が把握しやすい

クロス集計表とグラフの例

人数		満足度				計
		すごく満足	まあまあ満足	やや不満	すごく不満	
の予想 比較額 と 少なかった	多かった	5	2	0	0	7
	予想通り	10	9	6	0	25
	少なかった	0	0	2	6	8
計		15	11	8	6	40




散布図の例



相関

- 2変数の一方の値が大きい時には他方も大きいという関係がある
→ 正の相関があるという
- 2変数の一方の値が大きい時に他方は小さいという関係がある
→ 負の相関があるという



25

やってみよう

- 準備
 - [data06.xlsx](#) を, Sc188 フォルダにダウンロードして開く
- ワークシート「住宅価格」の [MedHouseVal](#) で
 - 基本統計量を計算してみよう
 - 箱ひげ図, ヒストグラム を描いてみよう
- (option) ワークシート「住宅価格」の [MedInc](#)と[MedHouseVal](#) で
 - 散布図を描いてみよう
 - 相関はありそうだろうか. あるとしたら, 正負のどちらだろうか

26

やってみよう (つづき)

- ワークシート「お年玉」の [予想額との比較](#)と[満足度](#)で
 - クロス集計表 (ピボットテーブル) を作成してみよう
 - 集合縦棒グラフ, 3D縦棒グラフ を描いてみよう
 - 相関はありそうだろうか. あるとしたら, 予想額との比較が多いほど (満足, 不満) のどちらだろうか
- ワークシート「お年玉」の [小遣い額](#)と[お年玉額](#)で
 - 散布図を描いてみよう
 - 相関はありそうだろうか. あるとしたら, 正負のどちらだろうか

27