

数え上げと確率・統計

データサイエンスやAIの基礎として、確率・統計は重要
今回はそのあたりの話

数え上げ (場合の数)

- 場合の数を数え上げることは、確率の計算に必要

$$\text{事象 } A \text{ が生起する確率} = \frac{\text{事象 } A \text{ が生起する場合の数}}{(\text{等確率で生起する}) \text{すべての場合の数}}$$

- 場合の数を数えるときは、数えるべきものを全て1回ずつ、正確に数えることが重要
 - 未カウント (数えもらすこと) をしないように注意
 - ダブルカウント (重複して数えること) にも注意
 - 重複していることが分かっていたら、その分を差し引くなど
 - 重複回数が分かっていたら、その回数で割るなど

1

2

基本的な数え上げ

- **順列** ${}_nP_r$:
異なる n 個から r 個を順に取り出すときの場合の数 (順序あり)
- **組み合わせ** ${}_nC_r$:
異なる n 個から1度に r 個を取り出すときの場合の数 (順序なし)

$${}_nP_r = \overbrace{n \times (n-1) \times \cdots \times (n-(r-1))}^{r \text{ 個}} = \frac{n!}{(n-r)!}$$

$${}_nC_r = \frac{{}_nP_r}{{}_rP_r} = \frac{{}_nP_r}{r!} = \frac{n!}{r!(n-r)!}$$

3

基本的な数え上げ

- **重複順列** ${}_n\Pi_r$:
異なる n 個から1個取り出して戻す操作を r 回行った時の場合の数 (順序あり, 重複あり)
- **重複組み合わせ** ${}_nH_r$:
 n 種類の物から重複を許して1度に r 個を選ぶ時の場合の数 (順序なし, 重複あり)

$${}_n\Pi_r = n^r$$

$${}_nH_r = {}_{n+r-1}C_r = \frac{(n+r-1)!}{r!(n-1)!}$$

4

例

- n 人の誕生日のすべての場合の数：

$${}_{365}\Pi_n = 365^n$$

- n 人の誕生日がすべて異なる (同じ誕生日の人がいない) 場合の数：

$${}_{365}P_n = \overbrace{365 \cdot 364 \cdot 363 \cdot \dots \cdot (365 - (n - 1))}^{n\text{個}} = \frac{365!}{(365 - n)!}$$

- n 人の中に、同じ誕生日の人がいる場合の数：

$${}_{365}\Pi_n - {}_{365}P_n$$

5

例

- n 人の誕生日がすべて異なる確率 $p(n)$ は、[スライド5](#)より

$$\begin{aligned} p(n) &= \frac{{}_{365}P_n}{{}_{365}\Pi_n} = \frac{\overbrace{365 \cdot 364 \cdot 363 \cdot \dots \cdot (365 - (n - 1))}^{n\text{個}}}{\underbrace{365 \cdot 365 \cdot 365 \cdot \dots \cdot 365}_{n\text{個}}} \\ &= \frac{\overbrace{365 \cdot 364 \cdot 363 \cdot \dots \cdot (365 - (n - 2))}^{n-1\text{個}}}{\underbrace{365 \cdot 365 \cdot 365 \cdot \dots \cdot 365}_{n-1\text{個}}} \cdot \frac{365 - (n - 1)}{365} = p(n - 1) \cdot \frac{366 - n}{365} \end{aligned}$$

となる

※ $p(1) = 1$ から順に計算できる (あとで Excel で計算してみる)

7

確率

- すべての場合が等確率で生起すると仮定したとき、事象 A が生起する確率を $P(A)$ と表す
- $P(A)$ は以下のように表される

$$P(A) = \frac{\text{事象 } A \text{ が生起する場合の数}}{\text{すべての場合の数}}$$

6

例 (つづき)

- n 人の中に、同じ誕生日の人がいる確率 $q(n)$ は、[スライド5](#)より

$$q(n) = \frac{{}_{365}\Pi_n - {}_{365}P_n}{{}_{365}\Pi_n} = 1 - \frac{{}_{365}P_n}{{}_{365}\Pi_n} = 1 - p(n)$$

となる

8

余事象・排反事象

- 事象 A に対して、「 A が起こらない」という事象を A の余事象といい、 $\bar{A}$ で表す

- A と $\bar{A}$ に関して、以下が成り立つ

$$P(A) + P(\bar{A}) = 1 \quad \text{すなわち} \quad P(\bar{A}) = 1 - P(A)$$

※ 先の例の「 n 人の誕生日がすべて異なる」と「 n 人の中に、同じ誕生日の人がいる」は互いに余事象である

- 事象 A と事象 B が同時に起こらないとき、 A と B は互いに排反である、または排反事象であるという (A と $\bar{A}$ は排反事象である)

9

和事象・積事象

- 事象 A と B のいずれか (または両方) が起こるという事象を A と B の和事象といい、 $A \cup B$ で表す
- 事象 A と B の両方が起こるという事象を A と B の積事象といい、 $A \cap B$ で表す
- 和事象と積事象に関して、以下が成り立つ
 - $P(A \cup B) = P(A) + P(B) - P(A \cap B)$
 - A と B が排反事象の時、 $P(A \cap B) = 0$
 - A と B が排反事象の時、 $P(A \cup B) = P(A) + P(B)$ (和の法則)

10

独立事象

- 2つの事象 A, B の一方の起こる確率が、他方が起こったか否かによって影響を受けないとき、 A と B は互いに独立である、または独立事象であるという

- 独立事象に関して、以下が成り立つ

- A と B が互いに独立である時、

$$P(A \cap B) = P(A) \cdot P(B) \quad \text{(積の法則)}$$

11

条件付き確率

- 事象 A が起こった場合に限定した時の事象 B の確率を $P(B|A)$ と表す。このような確率を条件付き確率という

$$P(B|A) = \frac{\text{事象 } A \cap B \text{ が起こる場合の数}}{\text{事象 } A \text{ が起こる場合の数}}$$

- 条件付き確率に関して、以下が成り立つ (→ [次スライド](#))
 - $P(A \cap B) = P(A) \cdot P(B|A) = P(B) \cdot P(A|B)$
- A と B が互いに独立であるとき、以下が成り立つ (→ [積の法則](#))
 - $P(B) = P(B|A)$ かつ $P(A) = P(A|B)$

12

条件付き確率

($P(A \cap B) = P(A) \cdot P(B|A)$ の説明)

$$\begin{aligned} P(A \cap B) &= \frac{\text{事象 } A \cap B \text{ が起こる場合の数}}{\text{すべての場合の数}} \\ &= \frac{\text{事象 } A \text{ が起こる場合の数}}{\text{すべての場合の数}} \cdot \frac{\text{事象 } A \cap B \text{ が起こる場合の数}}{\text{事象 } A \text{ が起こる場合の数}} \\ &= P(A) \cdot P(B|A) \end{aligned}$$

※ $P(A \cap B) = P(B) \cdot P(A|B)$ についても同様

13

確率変数と確率分布

- さまざまな値をとる変数で、どのような値をとるかが確率的に定まるものを**確率変数**という
- 確率変数がどのような確率でどのような値をとるかを**確率分布**という
 - 確率変数が**離散データ**の場合、各値に対して「その値をとる確率」を対応付ける関数 (**確率質量関数**) で表される
 - 確率変数が**連続データ**の場合、値の区間に対して、その区間内の値をとる確率を定める関数 (**確率密度関数**) で表される

14


確率分布の例 (離散データの場合)

- さいころの目に対応する確率変数 X に対する確率分布は

$$P(X=1) = P(X=2) = \cdots = P(X=6) = \frac{1}{6}$$

となる。表や図であらわすと以下の通り

X	1	2	3	4	5	6
$P(X)$	$\frac{1}{6}$	$\frac{1}{6}$	$\frac{1}{6}$	$\frac{1}{6}$	$\frac{1}{6}$	$\frac{1}{6}$




※ 確率なので、合計は1になる

15

確率分布の例 (連続データの場合)

- 平均 0, 標準偏差 1 の**正規分布** (後述) に従う確率変数 X の確率分布は、右図のようなグラフの確率密度関数で表される
- 区間 (a, b) の値をとる確率 $P(a < X < b)$ は、斜線部の面積 (積分値) で表される

※ グラフと横軸の間の面積 (全区間の積分値) は 1 になる



16

確率分布の推定

- 母集団の確率分布が未知であっても、十分大きな標本の度数分布をその標本数で割ることで、母集団の確率分布を推定(近似)できる (cf. テキスト p.128, II.1-9).
- 確率分布に対しても、平均、分散、標準偏差、中央値、四分位数、最頻値等の統計量を定めことができる
 - 母集団から選んだ標本のこれらの統計量は、標本数が増えるにつれて、母集団 (の確率分布) のこれらの統計量に収束する
 - したがって、十分大きな標本のこれらの統計量で、母集団 (の確率分布) のこれらの統計量を推定(近似)できる

17

(離散的) 確率分布の統計量 (つづき)

離散的な値 $x_1, x_2, \dots, x_n$ (但し, $i < j$ ならば $x_i < x_j$) を, 各々 $P_{x_1}, P_{x_2}, \dots, P_{x_n}$ の確率で取る確率変数 X の確率分布について

- $P_{x_1}, P_{x_2}, \dots$ を順に足していったら、0.25, 0.5, 0.75 に到達したところの x_i が, 各々 第1四分位数, 中央値, 第3四分位数 である
- P_{x_i} が最大の x_i が 最頻値 である

※ 連続的な値をとる確率変数の確率分布についても、同様の考えで (積分を用いて) これらの統計量が計算できるが、ここでは割愛する

19

(離散的) 確率分布の統計量

離散的な値 $x_1, x_2, \dots, x_n$ (但し, $i < j$ ならば $x_i < x_j$) を, 各々 $P_{x_1}, P_{x_2}, \dots, P_{x_n}$ の確率で取る確率変数 X の確率分布について

- 平均値 μ は, $x_1 P_{x_1} + x_2 P_{x_2} + \dots + x_n P_{x_n} = \sum_{i=1}^n x_i P_{x_i}$ である. この値は期待値とも呼ばれ, $E(X)$ と書かれることもある
- 分散 σ^2 は, $(x_1 - \mu)^2 P_{x_1} + (x_2 - \mu)^2 P_{x_2} + \dots + (x_n - \mu)^2 P_{x_n} = \sum_{i=1}^n (x_i - \mu)^2 P_{x_i}$ で, 標準偏差 σ はその平方根である

18

正規分布

- 身長や体重や測定誤差など、自然界のさまざまなデータの多くは、その分布がおおよそ正規分布と呼ばれる分布になるといわれている
- 平均 μ , 分散 σ^2 の正規分布の確率密度関数 $f(x)$ は

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

で表される.

- 後述する推測統計では、さまざまな分布が正規分布であると仮定して推測することも多い
- 他にもさまざまな確率分布がある


20

母集団と標本 (§6-3)

- **全数調査**：全ての対象からデータを取る
→ 現実的でないことも多い(日本人全員の調査とか無理！)
↓
- **標本調査**(サンプル調査)：全ての対象からいくつか選んで行う調査
 - **母集団**：対象全体の集合
 - **標本**(サンプル)：母集団から選んだ調査対象
 - **抽出**：母集団から標本を選ぶこと
 - **無作為抽出**：母集団からランダム(でたらめ)に標本を選ぶこと
 - **標本誤差**：母集団と標本の間の(平均などの統計量の)誤差

21

全数調査と標本調査



22

記述統計と推測統計

- **記述統計**：得られたデータを，基本統計量や図表を用いて分析し，その特徴を捉える (**全数調査**で用いられる)
- **推測統計**：母集団が一定の確率分布を持つと仮定し，得られたデータはその母集団の標本と考えて，母集団の特徴を推測する (**標本調査**で用いられる)
 - **検定**：母集団についての仮説を判定する
 - 判定したい仮説 (**対立仮説**) が成り立たないという仮説 (**帰無仮説**) が成立する確率を計算し，それが十分小さいならば，帰無仮説が**棄却**されたとみなし，対立仮説は**有意**である(成立する可能性が高い)と判定するもの

23

記述統計と推測統計

- 推測統計 (つづき)
 - **点推定**：標本の特性値(基本統計量など)から母集団の特性値を推定し，その誤差 (**標本誤差**) を見積もる
 - **区間推定**：母集団が正規分布に従うと仮定できる場合，母集団の特性値を，幅を持った区間 (**○○%信頼区間**，例えば95%信頼区間 など) として推定する
- ※ **標本数が増えれば増えるほど**，標本誤差も信頼区間も小さくなる
→ **より正確な推定が行える**

24

中心極限定理

- 母集団がどのような分布であるかによらず，母集団の平均値，分散が μ, σ^2 であるとき，無作為に選んだ標本の平均値は，標本数 n が大きくなるにつれて，平均値，分散が $\mu, \frac{\sigma^2}{n}$ の正規分布に近づくという定理

※ 標本数 n が大きくなると，標本の平均値の分散 $\frac{\sigma^2}{n}$ は反比例して小さくなる (すなわち，平均値の標本誤差が小さくなる) ということを示している

25

やってみよう – 誕生日のパラドックス

- 「1人ずつ誕生日を調べ， n 人目で初めて同じ誕生日の人が出現する」という事象を確率変数 X を用いて $X = n$ と表し，その生起確率 $P(X = n)$ を表す関数 (確率質量関数) を $r(n)$ とすると：
 - $n = 1$ のときは 0
 - $n > 1$ のときは， $n - 1$ 人目までの誕生日がすべて異なり，かつ n 人目の誕生日が，その $n - 1$ 人の誰かの誕生日と一致する確率

なので， $r(n) = \begin{cases} 0 & (n = 1) \\ p(n-1) \cdot \frac{n-1}{365} & (n > 1) \end{cases}$ となる

27

やってみよう – 誕生日のパラドックス

Excel を使って誕生日のパラドックスに関する計算をしてみよう

- n 人の誕生日がすべて異なる確率 $p(n)$ は，[スライド7](#)より

$$p(n) = \begin{cases} 1 & (n = 1) \\ p(n-1) \cdot \frac{366-n}{365} & (n > 1) \end{cases}$$

- n 人の中に，同じ誕生日の人がいる確率 $q(n)$ は，[スライド8](#)より

$$q(n) = 1 - p(n)$$

26

やってみよう – 誕生日のパラドックス

- まとめると，以下ようになる

$$\begin{aligned} p(n) &= \begin{cases} 1 & (n = 1) \\ p(n-1) \cdot \frac{366-n}{365} & (n > 1) \end{cases} \\ q(n) &= 1 - p(n) \\ r(n) &= \begin{cases} 0 & (n = 1) \\ p(n-1) \cdot \frac{n-1}{365} & (n > 1) \end{cases} \end{aligned}$$

これを，ワークシート「誕生日」で計算してグラフ化してみよう

28

デモンストレーション – 中心極限定理

先週用いた「カリフォルニア州の各地域内の住宅価格データ」の MedHouseVal（データ数 20640）を用いて，中心極限定理が成立するか確かめてみる．

- MedHouseVal から，ランダムに1000個の標本を取り出して平均（標本平均）を求める
- それを50000回行って，50000個の標本平均を得る
 - 標本平均の分布は正規表現に近いだろうか
 - 標本平均の平均値と母集団の平均値はほぼ同じだろうか
 - 標本平均の分散はと母集団の分散のほぼ1000分の1だろうか