

データの収集と加工

データサイエンスで扱うデータは、RDB (関係データベース) の
テーブル (表) のような形式が多い
今回はそのようなテーブルの操作について学ぶ


RDB (関係データベース) の構造

- **データベース** : テーブル (表, リレーション) の集合
 - **テーブル** : **行**と**列**からなる2次元の構造で, 固有の**名前**を持つ
 - **行** : 1行が1件のデータで, 各**列 (属性)** に対応する**フィールド**を持つ. 表示の際には順序を定めることが多いが, 原則的には順不同. (**レコード**, **組**, **タプル** と呼ぶことも)
 - **フィールド** : 個々の値を持つ領域 (**Excel のセル** に対応)
 - **列** : 各列は**名前 (属性名)** を持つ. 表示の際には順序を定めることが多いが, 原則的には順不同. (**属性** と呼ぶことも)

1

2

RDB (関係データベース) の構造



3

テーブルの主な操作

- **選択 (selection)**
テーブルから, いくつかの行を選び出す操作
制限 (restriction) ともいう
- **射影 (projection)**
テーブルから, いくつかの列を選び出す操作
- **結合 (join)**
2つのテーブルを, 共通の属性を対応付けることによって,
1つのテーブルにまとめる操作 (後で例を見せます)

4

テーブルの主な操作

- 同じ属性名リストを持つ2つのテーブルを、行を要素とする集合として見た時の集合演算
 - **和** (union)
2つのテーブルの行を1つにまとめる操作 (重複行はまとめる)
 - **差** (difference)
一方のテーブルから、他方のテーブルに含まれる行を除く操作
 - **積** (intersection; 交わり)
2つのテーブルの両方に含まれる行のみのテーブルを作る操作

5

テーブルの正規化

- テーブルの中の重複する情報を取り除くために、テーブルを複数のテーブルに分けることを**正規化**といい、正規化された状態を**正規形**という
- 格納された情報の整合性を維持するには、正規形で格納しておくことが望ましい
- 分けられたテーブルは、結合によって1つのテーブルに復元できるので、テーブルを表示する際には結合してから表示することも多い
→ モデルとビューの分離

7

テーブルの主な操作

- ※ 以下の操作はテーブル自体を変更するものではないが、見た目を変えるものである
- (行の) 並べ替え (sorting)
テーブルの各行を、何らかの基準で並べ替える操作
 - (列の) 並べ替え
列の順序を並べ替える操作

6

正規化されていないテーブルの例


科目番号	期	クラス	曜/時	教室	科目名	区分	先修	教員名	勤務	研究室
Sc184	前	A	月1	JD201-2	IT基礎演習	IT	-	上 泰	専	JD306
Sc184	前	B	月2	JD201-2	IT基礎演習	IT	-	上 泰	専	JD306
Sc184	前	C	火1	JD201-2	IT基礎演習	IT	-	高田 茂樹	非	-
Sc184	後	-	火3	JD202	IT基礎演習	IT	-	山下 雅啓	非	-
Sc188	後	A	月1	JD202	データサイエンス入門	IT	Sc184	上 泰	専	JD306
Sc188	後	B	水1	JD202	データサイエンス入門	IT	Sc184	三浦 欽也	専	JD315
Sc188	後	C	水2	JD202	データサイエンス入門	IT	Sc184	三浦 欽也	専	JD315

- 例えば、「IT基礎演習」の科目区分が変わったり、教員の研究室が変わったりしたとき、該当するフィールドを探して出して、いちいち修正しなければならない
→ 書き換えミスやエラー (不整合) が起こる危険がある

8

テーブルの正規化の例

科目番号	期	クラス	曜/時	教室	科目名	区分	先修	教員名	勤務	研究室
Sc184	前	A	月1	JD201-2	IT基礎演習	IT	-	上 泰	専	JD306
Sc184	前	B	月2	JD201-2	IT基礎演習	IT	-	上 泰	専	JD306
Sc184	前	C	火1	JD201-2	IT基礎演習	IT	-	高田 茂樹	非	-
Sc184	後	-	火3	JD202	IT基礎演習	IT	-	山下 雅啓	非	-
Sc188	後	A	月1	JD202	データサイエンス入門	IT	Sc184	上 泰	専	JD306
Sc188	後	B	水1	JD202	データサイエンス入門	IT	Sc184	三浦 欽也	専	JD315
Sc188	後	C	水2	JD202	データサイエンス入門	IT	Sc184	三浦 欽也	専	JD315



データ分析の前処理

- 収集したデータは、分析処理をしやすい形をしているとは限らない
 - 余分な情報は取り除いた方が扱いやすい
 - 複数のデータを組み合わせる必要があることもある
- 先のRDBの操作 (テーブルの操作) が役に立つ
- データに不具合があることもある
- **データクレンジング** (次項) が必要

データクレンジング

- 収集したデータには、不具合のあることも多い
 - 表記のゆらぎがあると、本来同じものとして扱うべきものが、異なったものとして扱われる危険性がある (例えば「ハサミ」と「はさみ」が混在している場合など)
 - データに 欠損値 (値が抜けていること) や 異常値 (誤った値等) があると、統計的な分析で不具合を生じることがある
 - 外れ値を取り除いた方が良い場合もある
- ↓
- 本来の処理の前段階として、これらの問題の解決を図ることを **データクレンジング** という

データクレンジングの実際

- 表記のゆらぎがある場合、表記を統一する
- 欠損値 (異常値、外れ値) のあるデータについては、
 - 欠損値 (異常値、外れ値) を含む 行全体を削除する、あるいは、
 - 欠損値を 適当な値で埋める、例えば、
 - 同じレコードの他の値から求まる場合は、その値で埋める
 - 同じ列のデータの代表値 (平均値、中央値、最頻値等) で埋める
- など
- ※ 手作業はミスを誘発するので、プログラムで一括して行うのがよい

やってみよう

- 準備：Visual Studio Code (VSCoDe) の初期設定
「[Visual Studio Code の日本語化と初期設定](#)」に沿って行う
- 1. Visual Studio Code の起動
- 2. エクスプローラーの「フォルダーを開く」ボタンで、以前に作った Sc188 を開く
- 3. 歯車アイコンから設定のページを開き、資料に沿って「おすすめの設定項目」の設定を行う
 - Emmet: Show Expanded Abbreviation と HTML: Auto Closing Tags は飛ばしてよい

13

やってみよう

- 準備：Visual Studio Code (VSCoDe) の初期設定 (つづき)
 1. 以下の拡張機能をインストールする
 - Print
 - Python と Jupyter
- Moodle から [data08.xlsx](#) と [data08.ipynb](#) の2つのファイルを Sc188 フォルダにダウンロードする
- data08.xlsx を開いて、どのような表があるか見ておく
- VSCoDe で data08.ipynb を開き、内容を確認しながら実行する

14