

データ分析の実際 1

～ 時系列データ分析 ～

回帰分析

- さまざまな現象において、原因となる変数 (説明変数, 独立変数) と、結果として得られる変数 (目的変数, 従属変数) の間の関係を数式 (モデル) にあてはめて近似・推測することを回帰分析という
- 例えば、説明変数が X 、目的変数が Y 、モデルが $Y = AX + B$ (A, B は定数パラメータ) の場合、 X, Y の (現実の) 値の組 $(x_1, y_1), (x_2, y_2), \dots (x_n, y_n)$ に対して $y_1 \doteq Ax_1 + B, y_2 \doteq Ax_2 + B, \dots y_n \doteq Ax_n + B$ となるような定数パラメータ A, B を求めるのが目標となる (これは1次回帰 (線形回帰) と呼ばれる。 回帰直線 の式でもある)

1

2

回帰分析

- 説明変数が1つの場合を単回帰、2つ以上の場合を重回帰という
先のスライドの例は線形の単回帰であったが、例えば変数が $X_1, X_2, \dots X_k$ の (線形の) 重回帰の場合、モデルは $Y = A_1 X_1 + A_2 X_2 + \dots + A_k X_k + B$ という1次式となる
- 一般的には、単に「回帰分析」「重回帰分析」と言うと、線形回帰 (説明変数の1次式のモデル) をさす場合が多いが、広義にはそれ以外のモデル (2次以上の多項式や指数関数など) もある
- パラメータの決定は、通常、与えられたデータにおける誤差 (モデルによって計算される y と観測値の y の差) の二乗和が最小になるように定めるのが一般的である (最小二乗法)

3

時系列データ分析とは

- 時間の経過と共に (連続的に) 変化する観測値 (時系列データ) を目的変数とし、時刻を説明変数とする回帰分析と捉えることができる。
- 通常、時系列データは定期的 (毎年、毎月、毎日、毎時、毎分、毎秒など) に観測されたデータであり、多くの場合、それらをもとに将来の傾向を予測するのが目的である。
- 既知のデータ全体を何らかのモデル (数式) にあてはめる方法もあるが、直前の一定期間のデータから次の時刻の値を予測するモデルを構成する方法もある (漸化式的な感じ)

4

時系列データの周期変動

- 時系列データは、天文学的な原因や経済的な原因などで、周期的な変動を含むことが多い。
 - 例えば、気温などの気象データは、通常1日周期、1年周期の規則的な変動を含む
 - 経済的なデータも、1年周期の規則的な変動を含むことが多い
 - それら以外の周期変動もありうる。例えば 氷河期-間氷期 の超長周期の変動や、景気変動におけるキチン循環、ジュグラー循環、クズネッツ循環、コンドラチェフ循環など (仮説の域を出ないものもあり、周期が一定していない場合もある)

5

時系列データの変動要因

- 時系列データは周期的な変動を含むことが多いため、その観測値を以下の4つの要因に分けて考えることが多い
 - 傾向変動 (Trend variation) — 全体的な変化傾向
 - 循環変動 (Cyclical variation) — 増減を繰り返す成分
 - 季節変動 (Seasonal variation) — 1年周期の変動
 - 不規則変動 (Irregular variation) — 上3つの変動を除いた残差
- 時系列データ (の観測値) は、これらを合成したものとみなされる
- このうち循環変動は抽出が難しいため、存在しないと仮定したり、傾向変動として1つにまとめてしまうことも多い


6

乗法モデルと加法モデル

- 時系列データ分析では、観測値は先の4つの変動 (以下 T,C,S,I と略する) の合成とみなすが、合成の仕方によって2種類のモデルがある
 - 乗法モデル: 観測値は T, C, S, I の積 ($T \times C \times S \times I$)
 - 加法モデル: 観測値は T, C, S, I の和 ($T + C + S + I$)
- いずれのモデルが妥当かは、観測値から推測する
 - 乗法モデルの場合、S の振幅は T に比例して増減する
 - 加法モデルの場合、S の振幅は一定

7

乗法モデルと加法モデル



※ 以後、データが含む変動要因を表すために、 $\times$, $+$ を省略して TCSI のように表記することがある

8

各変動要因への分解法

時系列データの観測値を4つの要因に分解する方法はいくつかある

- 観測値からまず季節変動 (S) を求め、それを取り除いたデータ (TCI) を平滑化して傾向変動 (T または TC) を求め、残りを不規則変動 (I) とする方法
- 観測値からまず傾向変動 (T または TC) を求め、それを取り除いたデータから季節変動 (S) を求め、残りを不規則変動 (I) とする方法

※ いずれの場合も、循環変動 (C) は、存在するならば、TC から何らかの方法で分離する

9

各変動要因への分解法 – まず季節変動を求める方法

1. 観測値 (TCSI) から季節変動 (S; 例えば月別の季節調整値) を求める (期別平均法 (月別平均法), 連環比率法などが用いられる)
2. TCSI から S を取り除いて季節調整済みのデータ (TCI) を得る (乗法モデル: S で割る, 加法モデル: S を引く)
3. TCI を平滑化 (細かいデコボコを均すこと) して傾向変動 (TC) を得る (移動平均法, 指数平滑法などが用いられる)
4. TCI から TC を取り除いた残差を不規則変動 (I) とする
5. (C が存在するなら) TC から (何らかのモデルに基づく) T を取り除いて C を得る

10

各変動要因への分解法 – まず傾向変動を求める方法

1. 観測値 (TCSI) に傾向変動 (TC) のモデルをあてはめて TC を得る (回帰分析 (最小二乗法) など)
2. TCSI から TC を取り除いて、SI を得る
3. SI から季節変動 (S) を求める (期別平均法 (月別平均法) など)
4. SI から S を取り除いた残差を不規則変動 (I) とする

11

不規則変動の定常性と信頼区間

- 不規則変動 (I) が、何らかの確率分布に従うと仮定した場合、その確率分布が時間の変化によらず常に一定である (平均, 分散等の統計量が変化しない) ことを定常性という
- 不規則変動以外の変動要因 (TCS) は、何らかのモデルに従うと仮定すると、将来の値も前方補外 (外挿) によって推定できるので、不規則変動の確率分布が定常性を持つと仮定すると、目的変数の将来の値の分布も見積もることができ、信頼区間 (例えば 95% は値がこの区間内に入るといような区間) を推定することもできる

12

やってみよう

マウナ・ロア気象観測所のCO₂データの分析

- vega_datasets というライブラリから取得できる, マウナ・ロア気象観測所のCO₂データを時系列データとして, 将来の変化を予測してみる
 - このデータは局所的な大気変動の影響を受けにくい高高度で測定した大気中のCO₂のデータである
- 予測には Prophet というベイズ統計モデルのライブラリを利用する
- Moodle から [data09.ipynb](#) を Sc188 フォルダにダウンロードし, VSCode で開いて内容を確認しながら実行してみよう

13

やってみよう (時間があれば)

- 同じくマウナ・ロア気象観測所のCO₂データを用いて, Excel + ソルバーアドインで, 別の方法で分析してみる
 - 傾向変動の数式モデルを仮定して, 誤差が最小になるように傾向変動と季節変動を調整する (加法モデルを仮定する)
 - 傾向変動のモデルは $T = AX^2 + BX + C$ と $T = e^{AX+B} + C$ (e は自然対数の底(定数), X は説明変数, A, B, C はパラメタ) の2通りでやってみる
- [data09.xlsx](#) を Sc188 フォルダにダウンロードし, Excel で開いて内容を確認しながら実行してみよう

14