

データ分析の実際 1

～ 時系列データ分析 ～

時系列データとは？

- 時間の経過と共に (連続的に) 変化する観測値を時系列データという
- 時系列データは、通常、定期的 (毎年、毎月、毎日、毎時、毎分、毎秒 など) に観測されたデータとして与えられる
- したがって時系列データは、通常、時刻と、その時刻における観測値の組を、時刻順に並べたものとして与えられる (右表に一例を示す)

日付	最高気温 (°C)
2023/1/1	11.3
2023/1/2	9.7
2023/1/3	10.6
⋮	⋮

1

2

時系列データ分析

- 時系列データの時刻 t と 観測値 y_t の間の関係や法則性を見出そうとする分析
- 分析結果をもとに、未知の値 (将来の傾向など) を推定する
- 分析の手法には様々なものがある
 - 観測値 y_t (の推定値) を時刻 t の関数として表す方法 ($y_t \triangleq F(t)$)
 - 以前の観測値から、次の時刻の観測値を推定する方法 ($y_t \triangleq G(y_{t-1}, y_{t-2}, \dots)$)

など

時系列データの特徴 ～ 周期変動

- 時系列データは、天文学的な原因や経済的な原因などで、周期的な変動を含むことが多い。
 - 例えば、気温などの気象データは、通常1日周期、1年周期の規則的な変動を含む
 - 経済的なデータも、1年周期の規則的な変動を含むことが多い
 - それら以外の周期変動もありうる。例えば 氷河期 $\leftrightarrow$ 間氷期の超長周期の変動や、景気の循環 (好景気 $\leftrightarrow$ 不景気) など (周期が一定であるとは限らない)

3


4

時系列データの変動要因

- 時系列データは周期的な変動を含むことが多いため、その観測値を以下の4つの要因に分けて考えることが多い
 - 傾向変動 (Trend variation) — 全体的な変化傾向
 - 循環変動 (Cyclical variation) — 増減を繰り返す成分
 - 季節変動 (Seasonal variation) — 1年周期の変動
 - 不規則変動 (Irregular variation) — 上3つの変動を除いた残差
- 時系列データ (の観測値) は、これらを合成したものとみなされる
- このうち循環変動は抽出が難しいため、存在しないと仮定したり、傾向変動として1つにまとめてしまうこともある

5

時系列データの変動要因



6


乗法モデルと加法モデル

- 時系列データ分析では、観測値 Y は先の4つの変動 (以下 T, C, S, I と略する) の合成とみなすが、合成の仕方によって2種類のモデルがある
 - 乗法モデル: 観測値 Y は T, C, S, I の積 ($Y = T \times C \times S \times I$)
 - 加法モデル: 観測値 Y は T, C, S, I の和 ($Y = T + C + S + I$)
- いずれのモデルが妥当かは、観測値から推測する
 - 乗法モデルの場合、季節的な変動の振幅は T に比例して増減する
 - 加法モデルの場合、季節的な変動の振幅は一定

※ 先のスライドは加法モデルであった

7


乗法モデルと加法モデル



8

各変動要因への分解

- 便宜上、以下では加法モデルで考えることとする。また、 $T+C$ をまとめて傾向変動 (T) と考え、循環変動 (C) は考えないものとする



- また、以下では、データが含む変動要因を表すために、例えば $T+S$ の $+$ を省略して、 TS のように表記することがある

9

各変動要因への分解

時系列データの観測値を各変動要因 (T, S, I) に分解する方法は、主に2つある

- 観測値からまず 季節変動 (S) を求め、その S を取り除いたデータ (TI) から 傾向変動 (T) を求め、残りを 不規則変動 (I) とする方法
- 観測値からまず 傾向変動 (T) を求め、その T を取り除いたデータ (SI) から 季節変動 (S) を求め、残りを 不規則変動 (I) とする方法

※ 循環変動 (C) を分離する必要がある場合は、いずれの場合も、 T (本当は TC) から何らかの方法で分離する


10

各変動要因への分解法 — まず季節変動を求める方法

- 観測値 (TSI) から季節変動 (S ; 季節調整値 と呼ばれる) を求める
 - 月別平均法 (各年度の同じ月の値の (月ごとの) 平均を用いる方法)
 - 連環比率法 (各月の前月からの増減の比率を用いる方法)
- 観測値 (TSI) から S を引いて 季節調整済み のデータ (TI) を得る
- TI を 平滑化 (細かいデコボコを均すこと) して傾向変動 (T) を得る
 - 移動平均法 (一定期間の値の平均値を T の値とする方法)
 - 指数平滑法 (遡るほど重みを小さくした、重みづけ移動平均)
- TI から T を引いた残りを不規則変動 (I) とする

11

各変動要因への分解法 — まず季節変動を求める方法




12

各変動要因への分解法 — まず傾向変動を求める方法

1. 観測値 (TSI) に傾向変動 (T) のモデルをあてはめて T を得る
 - **回帰分析** (傾向変動の数式をあてはめて、誤差の二乗の合計が最小になるように係数を定める方法: **最小二乗法**) 等
2. 観測値 (TSI) から T を引いて SI を得る
3. SI から季節変動 (S) を求める (**月別平均法** など)
4. SI から S を引いた残りを不規則変動 (I) とする

13

各変動要因への分解法 — まず傾向変動を求める方法



14

不規則変動の定常性と信頼区間

- 不規則変動 (I) が、何らかの確率分布に従うと仮定した場合、その確率分布が時間の変化によらず常に一定である (平均、分散等の統計量が変化しない) ことを **定常性** という
 - 不規則変動以外の変動要因 (TCS) が、何らかのモデルに従うと仮定すると、将来の値も前方補外 (**外挿**) によって推定できる
 - 不規則変動の確率分布が定常性を持つと仮定すると、目的変数の将来の値の散らばりも見積もることができる
- 例えば、信頼区間 (値が〇〇%の確率でこの区間内に入るというような区間) を推定するような際に役立つ

15

やってみよう

マウナ・ロア気象観測所のCO₂データの分析

- vega_datasets というライブラリから取得できるマウナ・ロア気象観測所の CO₂ データを時系列データとして、将来の変化を予測してみる
 - このデータは局所的な大気変動の影響を受けにくい高高度で測定した大気中の CO₂ のデータである
- 予測には Prophet というモジュールを利用する
- Moodle から [data09.ipynb](#) を Sc188 フォルダにダウンロードし、VSCode で開いて内容を確認しながら実行してみよう

16

やってみよう (時間があれば)

- 同じくマウナ・ロア気象観測所のCO₂データを Excel で別の方法で分析してみる
 - 傾向変動の数式モデルを仮定して，誤差が最小になるように傾向変動のパラメータを調整し，季節変動を抽出する
 - 傾向変動のモデルは $T = BX + C$ (線形近似) と $T = AX^2 + BX + C$ (2次の多項式近似) の2通りでやってみる
 - 2000/4/1までのデータで分析して，2020/4/1までの予測値と実測値を比較し，2040/4/1までの予測値も見てみる
- [data09.xlsx](#) を Sc188 フォルダにダウンロードして Excel で遂行