

データ分析の実際 3


～ 教師あり学習 ～

(分類, 回帰)

AIの学習 (cf. 第5講)

AIの学習 (機械学習) には次の3つがある

- **教師あり学習**
問題と正解を訓練データとして学習，
問題から正解を導けるように学習する
- **教師なし学習**
入力データだけから，特徴やパターン
(規則性) などを見出す学習
- **強化学習**
種々の選択を試行錯誤し，報酬の高い
選択を選ぶように学習する




テキスト p.75, 図5-8

1

2

教師あり学習

- 訓練データとして「問題」(入力)と「正解」のセットを多数用意し，各問題に対して正解を解答(出力)できるように訓練する



3

教師あり学習の出力

- 教師あり学習の出力(解答, 正解)が質的データの場合，その値が入力データの 카테고리を表すと考えと，入力データを各々のカテゴリに分類する課題(分類タスク)とみなすことができる
※ 前回の講義のスパムメールフィルタはこの分類タスクの一例
- 教師あり学習の出力(解答, 正解)が量的データの場合，入力データ(x)と出力データ(y)の量的関係($y = f(x)$)となるような f を推定する課題(回帰タスク)とみなすことができる
※ 前々回の講義で取り上げた時系列データの分析は，この回帰タスクの一種ともみなせる

4


回帰分析

- さまざまな現象において、原因となる変数 (説明変数, 独立変数) と、結果として得られる変数 (目的変数, 従属変数) の間の関係を数式 (モデル) にあてはめて近似・推測することを回帰分析という
- 例えば、説明変数が X 、目的変数が Y 、モデルが $Y = AX + B$ (A, B は定数パラメータ) の場合、 X, Y の (現実の) 値の組 $(x_1, y_1), (x_2, y_2), \dots (x_n, y_n)$ に対して $y_1 \doteq Ax_1 + B, y_2 \doteq Ax_2 + B, \dots y_n \doteq Ax_n + B$ となるような定数パラメータ A, B を求めるのが目標となる (これは1次回帰 (線形回帰) と呼ばれる。回帰直線の式でもある)

5

(線形) 単回帰分析

- 入力データ (説明変数; x) と出力データ (目的変数; y) の量的関係を $y = Ax + B$ (A : 係数, B : 切片) という数式モデルで近似する (パラメータ A, B を決定する)
- x, y が各々1変数なので、近似した結果は x - y 平面のグラフとして図示できる
 - $y = Ax + B$ は直線を表すので、その直線 (回帰直線) で近似することになる



7

回帰分析

- 説明変数が1つの場合を単回帰, 2つ以上の場合を重回帰という
先のスライドの例は線形の単回帰であったが、例えば変数が $X_1, X_2, \dots, X_k$ の (線形の) 重回帰の場合、モデルは $Y = A_1X_1 + A_2X_2 + \dots + A_kX_k + B$ という1次式となる
- 一般的には、単に「回帰分析」「重回帰分析」と言うと、線形回帰 (説明変数の1次式のモデル) をさす場合が多いが、広義にはそれ以外のモデル (2次以上の多項式や指数関数など) もある

6

(線形) 重回帰分析

- 入力データ (説明変数; $x_1, \dots, x_n$) と出力データ (目的変数; y) の量的関係を $y = A_1x_1 + \dots + A_nx_n + B$ ($A_1, \dots, A_n$: 係数, B : 切片) という数式モデルで近似する (パラメータ $A_1, \dots, A_n, B$ の値を決定する)
- 1件1件の訓練データは、 $x_1, \dots, x_n, y$ の $n + 1$ 本の軸を持つ $n + 1$ 次元空間内の1点1点で表されるが、重回帰分析は、それらを $y = A_1x_1 + \dots + A_nx_n + B$ が表す超平面で近似することになる


8

最小二乗法

- 回帰分析におけるパラメータの決定は、通常、与えられたデータにおける誤差 (モデルによって計算される y と観測値の y の差) の二乗和が最小になるように定めるのが一般的である (最小二乗法)

教師あり学習としての回帰分析

- 回帰分析 (重回帰を含む) は、説明変数 (の観測値) を 問題, 目的変数 (の観測値) を 正解 と考えると、回帰タスクとみなすことができる




9

10

汎化と過学習


教師あり学習において、

- 訓練データで学習したAIが、(未知の) 新規データに対しても適切な出力を出せるようになることを 汎化 という
- 一方、訓練データに過度に適合した結果、かえって一般性を失い、(未知の) 新規データに適切に対応できなくなることを 過学習 という



11


汎化と過学習



12

過学習を避けるには

- 学習に、偏りのない、大量の訓練データを用いる
- 過学習になっていたら、学習モデルを修正してやり直す
 - 過学習になっていないかどうかのチェックが必要
- 母集団から得たデータを訓練データとテストデータに分けて、学習後にテストする(右図)



13

教師あり学習の手法


- 決定木学習 (分類)
- ランダムフォレスト (分類, 回帰)
 - 決定木学習によるアンサンブル学習の一種
- 順伝播型ニューラルネットワーク (FNN) (分類, 回帰)
 - ニューラルネットワーク (NN) の一種

など.

14

決定木学習

- 訓練データから決定木 (下図に例 (部分) を示す) を生成する学習方法




15

アンサンブル学習

- 1つの訓練データ(セット)から、重複を許したランダムサンプリングによって複数の訓練データ(セット)を生成し、その各々を用いて複数の「学習済みAI」を生成して、それらをまとめて一つのAIとする方法
- 全体の出力は、個々の「学習済みAI」の出力を合成する
 - 分類タスクの場合は、個々の出力の多数決(最頻値)を出力とする
 - 回帰タスクの場合は、個々の出力の平均値を出力とする
- ランダムフォレストは、決定木学習をベースにアンサンブル学習を行う教師あり学習の手法である

16


アンサンブル学習



17

順伝播型ニューラルネットワーク (FNN)

- 神経細胞を模したユニットを多数連結して並列に動作するモデル
- 1つのユニットは複数個の入力と1つの出力を持つ
- 並列に配置されたユニット群を層として複数の層を構成し、データが複数の層を順に伝わることで計算が行われる。




2層(3層)FNNの例
※ 入力層は数えないことも多い

18

ユニット

- n 入力, 1出力 ($n \geq 1$)
- 重みベクトル
 $\mathbf{w} = (w_0, w_1, w_2, \dots, w_n)$ と 活性化関数 f によって機能が定まる
- 入力ベクトル $\mathbf{x} = (x_1, x_2, \dots, x_n)$ に対する出力 z は下の式で計算される
$$z = f(w_0 + w_1x_1 + w_2x_2 + \dots + w_nx_n)$$



19

FNNにおける学習

- 構成する全ユニットの重みベクトルの値を修正することによって学習する (活性化関数はあらかじめ決めておく – 学習では変わらない)
- 各重みベクトルの値は、最初はランダムに与え、訓練データの出力と正解の誤差が減少するように、少しずつ修正し、誤差が十分小さくなるまで、同じ訓練データで何度も繰り返して学習する
- 出力層 (最終層) の出力は、一般には以下のようなものになる
 - 回帰タスクの場合は目的とする量的データ
 - 分類タスクの場合は各カテゴリに属する確率
(属する確率が最も高いカテゴリに分類されると判断する)

20

ハイパーパラメータについて

- 決定木学習やランダムフォレストやFNNなどのAIモデルは、そのふるまいを制御する多数のパラメータを持っている
 - 決定木では、末端ノードの最大数など
 - ランダムフォレストでは、決定木の数や決定木のパラメータなど
 - FNNでは、層の数、各層のユニット数、学習回数の上限などこれらのパラメータを特にハイパーパラメータと呼ぶ
- ハイパーパラメータの値は、学習の効率や最終的な精度を左右し、過学習の抑制も、これらのハイパーパラメータの調整によって行うことが多い

21

やってみよう – 分類 ([data11 1.ipynb](#))

- 南極 Palmer 基地の Kristen Gorman 博士から提供された 3種類の ペンギンの体の計測データ から、ペンギンの種類 を推定する (ペンギンを分類する) AI (分類器) を教師あり学習によって作成する
 - モデルは 決定木学習 (2方式)、ランダムフォレスト、2層FNN の4種
- 大まかな手順は以下の通り
 - データセットを訓練用(70%)とテスト用(30%)に分ける
 - 訓練データで学習させる
 - テストデータで評価する (混同行列、誤判定数と正解率) を求める
 - 決定境界図 (分類の境界を示した図) も見てみる

22

やってみよう – 回帰 ([data11 2.ipynb](#))

西宮市の中古マンションの取引情報 ([housing.csv](#)) を用いて、その物件の取引価格を推定する。

- 説明変数として、最寄り駅までの距離、部屋数、面積、取引時期、築年数 の一部、またはすべてを用い、目的変数は取引価格とする
- 以下の4通りの方法で推定する
 - 説明変数として築年数のみを用いた(線形)単回帰分析
 - すべての説明変数を用いた(線形)重回帰分析
 - すべての説明変数を用いた 2層FNN による学習
 - すべての説明変数を用いた ランダムフォレスト による学習

23

やってみよう – 回帰

(つづき)

- 結果は 決定係数 (R^2) と 二乗平均平方根誤差 (RMSE) で評価する
 - 決定係数は1に近い方が良い
 - 二乗平均平方根誤差 (RMSE) は、どのくらいの誤差があるかを金額で表すので、小さいほど良い
- 訓練データとテストデータの差 が大きいと、過学習の可能性がある

24