

データ分析の実際 4

～ 教師なし学習 ～

(クラスタリング, アソシエーション分析, など)

教師なし学習


主なものとして、以下のものが挙げられる

- クラスタリング (クラスター分析)
 - 与えられたデータを、それらの類似性を元に、複数のグループ (クラスター) に分類する手法
- アソシエーション分析
 - 複数の事象 (例えば「商品Aを買う」「商品Bを買う」など) のデータから、それらの関連性の規則 (アソシエーション・ルール) を見つける手法
 - 購買に関する分析は バスケット分析 と呼ばれる

AIの学習 (再掲)

AIの学習 (機械学習) には次の3つがある

- 教師あり学習
問題と正解を訓練データとして学習、問題から正解を導けるように学習する
- 教師なし学習
入力データだけから、特徴やパターンなどを見出す学習
- 強化学習
種々の選択を試行錯誤し、報酬の高い選択を選ぶように学習する



テキスト p.75, 図5-8

教師なし学習 (つづき)

- 次元削減
 - 多数の変数を持つデータを、できるだけ情報を損なわないように変数を減らす手法
 - 自己符号化器 (Auto Encoder; AE), 主成分分析, 因子分析, 自己組織化マップ (Self-organizing maps; SOM), 等
- 敵対的生成ネットワーク (Generative Adversarial Network; GAN)
 - 元データとそっくりな特徴を持つデータをランダムに生成するようなニューラルネットワークを構成する手法

クラスタリング

- n 変数のデータの1件を n 次元空間内の1点と考え、距離の近い点をひとまとめにすることによってクラスタを構成する (距離が近い=類似性が高いと考える)
 - 階層的クラスタリング (ウォード法など)
 - 最初は1データ1クラスタとし、目標となるクラスタ数になるまで、最も「近い」2つのクラスタの合併を繰り返す手法
 - 非階層的クラスタリング (k-means法など)
 - クラスタ数をあらかじめ与え、最も適切な分割を見つける手法

5

クラスタリングにおける距離

- n 次元空間における2点 $A = (a_1, \dots, a_n)$, $B = (b_1, \dots, b_n)$ の間の「距離」は、ユークリッド距離

$$\sqrt{\sum_{i=1}^n (a_i - b_i)^2}$$

を用いることが多いが、それ以外の「距離」を用いる場合もある (マンハッタン距離, マハラノビス距離, コサイン類似度など)

- クラスタリングは各変数 (座標軸) のスケールにも影響されるので、各変数は事前に正規化 (平均0, 標準偏差1に1次式で変換するなど) したほうがよい

6

アソシエーション分析

- 与えられたデータから、前提となる事象 (A とする) と結果となる事象 (C とする) について、 A が C (の確率) にどのような影響を与えるかの規則 (アソシエーション・ルール) を抽出し、有用な規則を見出すことを目的とする

例) 商品Aを買うという事象が、商品Cを買う確率にどういう影響を与えるかなど
- 各ルールの指標を見て、有用性を判断する
 - 指標には次スライドの表のようなものがある

7

アソシエーション・ルールの各種指標

指標	値
支持度 (support)	$P(A \cap C)$
確信度 (confidence)	$P(C A) = \frac{P(A \cap C)}{P(A)}$
リフト値 (lift)	$\frac{P(C A)}{P(C)} = \frac{P(A \cap C)}{P(A)P(C)}$
leverage	$P(A \cap C) - P(A)P(C)$
conviction	$\frac{1 - P(C)}{1 - P(C A)} = \frac{P(\bar{C})}{P(\bar{C} A)}$

8

アソシエーション・ルールの各種指標 (つづき)

- 支持度 (support)
 - 前提事象 A と結果事象 C の両方が起こる確率
- 確信度 (confidence)
 - 前提事象 A が起こっているときの、結果事象 C が起こる確率
- リフト値 (lift)
 - 前提事象 A が起こることによって、結果事象 C の起こる確率がどのくらいアップするか (何倍になるか)
 - 1 より大きいなら、 A は C に促進的な影響を与えている

9

アソシエーション・ルールの各種指標 (つづき)

- leverage
 - 前提事象 A と結果事象 C の両方が起こる確率について、実際の確率と A , C が独立であると仮定したときの確率との差
 - 0 より大きいなら、 A は C に促進的な影響を与えている
- conviction
 - 前提事象 A が起こることによって、結果事象 C の起こらない確率がどのくらいダウンするか (何分の1になるか)
 - 1 より大きいなら、 A は C に促進的な影響を与えている
 - リフト値が等しくても、 $P(C)$ の大きい方が大きい値になる

10

やってみよう – 教師なし学習

商品購買のデータを用いた[アソシエーション分析](#)と、「ペンギン」のデータ (先週[分類タスク](#)で用いたもの) を用いた[クラスタリング](#)を行う ([data12.ipynb](#))

- アソシエーション分析は、kaggle で提供されている商品購買のデータ (誰が何を買ったか ; [basket_data.csv](#)) を用いて、商品購買に関するアソシエーション・ルールを抽出する ([バスケット分析](#))
- クラスタリングは、ペンギンの種類のデータを伏せて、ペンギンの体の計測データのみを用い、[k-means法](#)、[ウォード法](#)、[GMM](#) の3通りの方法を用いて3クラスターに分けてみる。


11

(以下のスライドはおまけです)

12

自己符号化器 (Auto Encoder; AE) の構造


- 入力数と出力層のユニット数が同じの2層のFNN
- 訓練データの入力 $\mathbf{x}$ に対し、出力 $\mathbf{x}'$ を $\mathbf{x}$ に一致させるように学習させる
 - 入力 $\mathbf{x}$ に対する「正解」は $\mathbf{x}$ そのものなので、別途用意する必要はない
→ 教師なし学習



13

自己符号化器 (Auto Encoder; AE) の働き

- 中間層のユニット数は、入出力より少なくしておく (砂時計型; $m < n$)
- うまく学習できると、中間層の出力 $\mathbf{z}$ は、 $\mathbf{x}$ を復元するのに十分な情報を持つことになる (= $\mathbf{x}$ の情報を損なわずに変数を減らせる = 次元削減)




14

敵対的生成ネットワーク (GAN, GANs)

(Generative Adversarial Networks)

- 生成ネットワーク (Generator) と識別ネットワーク (discriminator) からなる。
 - 識別ネットワークは、入力が生成ネットワークの出力か訓練データかを識別できるように学習する。
 - 生成ネットワークは、ランダムノイズ等を元に、訓練データに類似したデータ (= 識別ネットワークが訓練データと誤認識するデータ) を出力するように学習する。

敵対的生成ネットワークの構成



15

16

敵対的生成ネットワークの応用例

- 低画質の画像を高画質にする
- モノクロ画像を着色する
- 有名画家の絵画を訓練データとして, その画家のようなタッチの画像を生成する (「贋作」を生成する? !)

など