

パーセプトロン

(ニューラルネットワーク入門)


1

1

ニューロセルの基本構造(1)

マカロック=ピッツ モデル

$x_1 \sim x_n$: 入力 (アナログ値もOK)
 $w_1 \sim w_n$: 重み
 θ : 閾値
 f : 活性化関数 (ステップ関数)



$$f(x) = \begin{cases} 0, & (x < 0) \\ 1, & (x \geq 0) \end{cases}$$

$$u = \sum_{i=1}^n w_i x_i - \theta \quad (= w_1 x_1 + \dots + w_n x_n - \theta)$$

$$z = f(u) \quad (u: \text{活性値}, z: \text{出力 (0 or 1)})$$


2

2

ニューロセルの基本構造(2)

現代的なモデル

$x_1 \sim x_n$: 入力 (アナログ値もOK)
 $w_1 \sim w_n$: 重み
 $w_0 (= -\theta)$: バイアス ($x_0 = 1$ とする)
 f : 活性化関数
 (シグモイド関数, ReLU等)



$$u = \sum_{i=0}^n w_i x_i \quad (= w_0 + w_1 x_1 + \dots + w_n x_n)$$


$$z = f(u) \quad (u: \text{活性値}, z: \text{出力 (アナログ値もOK)})$$

3

3

活性化関数


• 恒等関数




• ステップ関数



• シグモイド関数



• 正規化線形関数 (ReLU)



4

4


活性化関数

- 恒等関数 → 線形近似式
 - 多層化が無意味
- ステップ関数 → 線形判別式
- シグモイド関数：可微分
- 正規化線形関数 (ReLU)：片側可微分
- 他（さまざまに工夫されている）

5

ニューロセルの例 (マカロック=ピッツ モデル で考える)

$x_1 \sim x_n$: 入力
 $w_1 \sim w_n$: 重み
 θ : 閾値
 f : 活性化関数 (ステップ関数)



$$u = \sum_{i=1}^n w_i x_i - \theta \quad (= w_1 x_1 + \dots + w_n x_n - \theta)$$

$$z = f(u)$$

活性化値 (x_i の一次式)

6

ニューロセルの例 (2入力の場合(1))


$$w_1 = w_2 = 1$$

$$\theta = \frac{3}{2}$$

の場合,

$$x_1 + x_2 - \frac{3}{2} < 0 \text{ のとき } z = 0$$

$$x_1 + x_2 - \frac{3}{2} \geq 0 \text{ のとき } z = 1$$



7

ニューロセルの例 (2入力の場合(1))

$$w_1 = w_2 = 1$$

$$\theta = \frac{3}{2}$$

の場合,

$$x_1 + x_2 - \frac{3}{2} < 0 \text{ のとき } z = 0$$


$$x_1 + x_2 - \frac{3}{2} \geq 0 \text{ のとき } z = 1$$

x_1	x_2	z
0	0	0
0	1	0
1	0	0
1	1	1

z : x_1 かつ x_2

8

ニューロセルの例 (2入力の場合(1))



x_1	x_2	z
0	0	0
0	1	0
1	0	0
1	1	1

$z : x_1 \text{ かつ } x_2$


重み(w_i)と閾値(θ)によって境界の直線が定まる

9

ニューロセルの例 (2入力の場合(2))

x_1	x_2	z
0	0	1
0	1	1
1	0	0
1	1	1

$z : x_1 \text{ ならば } x_2$




適切な w_1 , w_2 , θ の値を考えてみよう

10

ニューロセルの例 (2入力の場合(2))

x_1	x_2	z
0	0	1
0	1	1
1	0	0
1	1	1

$z : x_1 \text{ ならば } x_2$




適切な w_1 , w_2 , θ の値を考えてみよう

11

ニューロセルの例 (2入力の場合(2))

x_1	x_2	z
0	0	1
0	1	1
1	0	0
1	1	1

$z : x_1 \text{ ならば } x_2$




適切な w_1 , w_2 , θ の値を考えてみよう

12

ニューロセルの例 (2入力の場合(2))

x_1	x_2	z
0	0	1
0	1	1
1	0	0
1	1	1

z : x_1 ならば x_2



適切な w_1 , w_2 , θ の値を考えてみよう

13

13

ニューロセルの例 (3入力の場合(1))


$$w_1 = w_2 = w_3 = 1$$

$$\theta = \frac{5}{2}$$

の場合,

$$x_1 + x_2 + x_3 - \frac{5}{2} < 0 \rightarrow z = 0$$

$$x_1 + x_2 + x_3 - \frac{5}{2} \geq 0 \rightarrow z = 1$$



14

14

ニューロセルの例 (3入力の場合(1))


$$w_1 = w_2 = w_3 = 1$$

$$\theta = \frac{5}{2}$$

の場合,

$$x_1 + x_2 + x_3 - \frac{5}{2} < 0 \rightarrow z = 0$$

$$x_1 + x_2 + x_3 - \frac{5}{2} \geq 0 \rightarrow z = 1$$



15

15

ニューロセルの例 (3入力の場合(2))

$$w_1 = w_2 = w_3 = 1$$


$$\theta = \frac{3}{2}$$

の場合,

$$x_1 + x_2 + x_3 - \frac{3}{2} < 0 \rightarrow z = 0$$

$$x_1 + x_2 + x_3 - \frac{3}{2} \geq 0 \rightarrow z = 1$$

重み(w_i)と閾値(θ)を変えれば境界の平面が変化する




16

16

n入力に一般化して考えると……


- 各入力はn次元立方体の各頂点に対応する
- $w_1x_1 + \dots + w_nx_n - \theta = 0$ は、n次元空間内のn-1次元超平面对応する
- 出力は、入力に対応する頂点が、上の超平面のどちら側にあるかで、0になるか1になるか定まる



17

n入力1出力単層ネットワーク

- 単一のセルと等価
= 重みと入力の内積 → 活性化関数




$$z_1 = f \left((w_{10} \ w_{11} \ \dots \ w_{1n}) \begin{pmatrix} 1 \\ x_1 \\ \vdots \\ x_n \end{pmatrix} \right)$$

18

n入力m出力単層ネットワーク

- 1出力のものをm個並列に並べる
= 重み行列と入力の積 → 活性化関数




$$z_1 = f \left((w_{10} \ w_{11} \ \dots \ w_{1n}) \begin{pmatrix} 1 \\ x_1 \\ \vdots \\ x_n \end{pmatrix} \right)$$

$$z_2 = f \left((w_{20} \ w_{21} \ \dots \ w_{2n}) \begin{pmatrix} 1 \\ x_1 \\ \vdots \\ x_n \end{pmatrix} \right)$$

19

n入力m出力単層ネットワーク

- 1出力のものをm個並列に並べる
= 重み行列と入力の積 → 活性化関数




$$\begin{pmatrix} z_1 \\ \vdots \\ z_m \end{pmatrix} = f \left(\begin{pmatrix} 1 & 0 & \dots & 0 \\ w_{10} & \ddots & & w_{1n} \\ \vdots & & \ddots & \vdots \\ w_{m0} & \dots & w_{mn} \end{pmatrix} \begin{pmatrix} 1 \\ x_1 \\ \vdots \\ x_n \end{pmatrix} \right)$$

$$\mathbf{z} = f(W\mathbf{x})$$

21

単層ネットワークの限界 (線形分離問題)

- 0になるべき入力と1になるべき入力を直線（超平面）で分けられない場合、単層のネットワークでは実現できない




- ↓
- 2層以上なら可能になる
- 多層になればなるほど、複雑な出力が生成できる

22

n入力m出力単層ネットワーク


- 1出力のものをm個並列に並べたもの



23

フィードフォワードネットワーク (FNN)

- 単層ネットワークを複数直列に並べる



24


パーセプトロン (=fがステップ関数のFNN) の学習

- 訓練パターン（入力 $\mathbf{x}$ と正しい出力 $\mathbf{z}^*$ のペア）の集合を用意（教師あり学習）
- 各訓練パターンで、入力 $\mathbf{x}$ に対する出力信号 $\mathbf{z}$ と教師信号 $\mathbf{z}^*$ の誤差を縮めるように、出力層（最終層）の重み・バイアス ($W^{(l)}$) を修正
- 誤差が無くなるまで反復する

25

パーセプトロン (= f がステップ関数の FNN) の学習

学習サンプル： 入力-出力の対 $(\mathbf{x}, \mathbf{z}^*)$



26

26

- 各ユニットごとに ...
- $\mathbf{e} = \mathbf{z}^* - \mathbf{z}$ の各成分が ...

0 ... 問題なし

+1 ... 活性値が小さすぎる(増やす必要)

-1 ... 活性値が大きすぎる(減らす必要)

下2つの場合に1だった入力に対する重み ($x_0 = 1$ としてバイアス w_0 を含む) を増減する (0だった入力の重みは変えない)

$$w_i \rightarrow w_i + \Delta w_i, \quad \Delta w_i = \varepsilon e x_i \quad (i = 0 \sim n, \quad \varepsilon: \text{学習係数})$$

行ベクトルとしてまとめると...

$$(w_0 \cdots w_n) \rightarrow (w_0 \cdots w_n) + \varepsilon e (x_0 \cdots x_n)$$

27

27

$$(w_0 \cdots w_n) \rightarrow (w_0 \cdots w_n) + \varepsilon e (x_0 \cdots x_n)$$

- 複数出力 (出力層が複数ユニット) の場合 ...

$$\mathbf{e} = \begin{pmatrix} e_1 \\ \vdots \\ e_m \end{pmatrix} = \begin{pmatrix} z_1^* \\ \vdots \\ z_m^* \end{pmatrix} - \begin{pmatrix} z_1 \\ \vdots \\ z_m \end{pmatrix} = \mathbf{z}^* - \mathbf{z} \text{ として,}$$

$$\begin{pmatrix} w_{10} & \cdots & w_{1n} \\ \vdots & \ddots & \vdots \\ w_{m0} & \cdots & w_{mn} \end{pmatrix} \rightarrow \begin{pmatrix} w_{10} & \cdots & w_{1n} \\ \vdots & \ddots & \vdots \\ w_{m0} & \cdots & w_{mn} \end{pmatrix} + \varepsilon \begin{pmatrix} e_1 \\ \vdots \\ e_m \end{pmatrix} (x_0 \cdots x_n)$$

すなわち、

$$\mathbf{W} = \mathbf{W} + \Delta \mathbf{W}, \quad \Delta \mathbf{W} = \varepsilon \mathbf{e} \mathbf{x}^T, \quad \mathbf{x}^T = (x_0 \cdots x_n)$$

28

28

訓練パターンが複数 $((\mathbf{x}_1, \mathbf{z}_1^*) \dots (\mathbf{x}_k, \mathbf{z}_k^*))$ の場合,

$$\mathbf{X} = (\mathbf{x}_1 \quad \cdots \quad \mathbf{x}_k)$$

$$\mathbf{E} = (\mathbf{e}_1 \quad \cdots \quad \mathbf{e}_k) = (\mathbf{z}_1^* \quad \cdots \quad \mathbf{z}_k^*) - (\mathbf{z}_1 \quad \cdots \quad \mathbf{z}_k) = \mathbf{Z} - \mathbf{Z}^*$$

とすると,

$$\sum_{i=1}^k \Delta \mathbf{W}_i = \varepsilon \sum_{i=1}^k \mathbf{e}_i \mathbf{x}_i^T = \varepsilon (\mathbf{e}_1 \quad \cdots \quad \mathbf{e}_k) \begin{pmatrix} x_1^T \\ \vdots \\ x_k^T \end{pmatrix} = \varepsilon \mathbf{E} \mathbf{X}^T$$

したがって、複数の訓練パターンでまとめて学習する場合、

$$\mathbf{W} = \mathbf{W} + \Delta \mathbf{W}, \quad \Delta \mathbf{W} = \varepsilon \mathbf{E} \mathbf{X}^T$$

29

29